

Algoritmo Genético Multiobjetivo para o Problema de Sequenciamento em Máquinas Paralelas Não-Relacionadas

Felipe Martins Müller

* Universidade Federal de Santa Maria - Centro de Tecnologia - UFSM/CT
Av. Roraima nº 1000, Cidade Universitária, Bairro Camobi, Santa Maria - RS
felipe@inf.ufsm.br

Angelita Pezzi Pasqualon Bridi *

angelitabridi@gmail.com

Guilherme Lopes Weis *

guilherme.weis@ebserh.gov.br

RESUMO

O consumo de energia tornou-se um tema de grande importância devido à crescente preocupação com as alterações climáticas e o declínio dos recursos energéticos fósseis. Nesse contexto, nosso estudo preocupa-se em reduzir o consumo de energia de um sistema fabril composto por n tarefas independentes em m máquinas paralelas não-relacionadas, tendo como objetivos minimizar o *makespan* e o consumo total de energia. Como o problema em questão é NP-Difícil, torna-se inviável resolvê-lo na otimalidade em um tempo computacional aceitável, principalmente para problema de grande dimensão, por isso implementamos e comparamos dois algoritmos genéticos multiobjetivo, o NSGA-II e o R-NSGA-II. As soluções obtidas com o algoritmo NSGA-II em relação ao R-NSGA-II foram superiores em 65% das instâncias quanto aos Pontos de Convergência, 45% quanto ao número de soluções não-dominadas (ND), 65% quanto a distribuição das soluções, 35% quanto a capacidade de minimizar o *makespan* e 60% quanto ao consumo total de energia.

PALAVRAS CHAVE. Máquinas Paralelas Não-relacionadas, Multiobjetivo, Consumo de Energia.

Tópicos: PO na Indústria.

ABSTRACT

The consumption of energy has become a matter of great importance due to increasing concern about climate change and the decline of fossil energy resources. In this context, our study aims to reduce the energy consumption of a manufacturing system consisting of n independent tasks on m unrelated parallel machines, with the objectives of minimizing the *makespan* and the total energy consumption. Since the problem at hand is NP-Hard, it is not feasible to solve it optimally within an acceptable computational time, especially for large-scale problems. Therefore, we implemented and compared two multi-objective genetic algorithms, namely NSGA-II and R-NSGA-II. The solutions obtained with the NSGA-II algorithm outperformed the R-NSGA-II algorithm in 65% of the instances regarding Convergence Points, 45% in terms of the number of non-dominated solutions (ND), 65% in terms of solution distribution, 35% in terms of the ability to minimize the *makespan*, and 60% in terms of total energy consumption.

KEYWORDS. Unrelated Parallel Machines. Multi-objective, Energy Consumption.

Paper topics: OR in Industry.

1. Introdução

Melhorar a eficiência energética tem estado recentemente na agenda de vários setores devido à escassez global de energia e seus efeitos no meio ambiente [Giret et al., 2015]. O setor industrial é visto como um consumidor significativo de energia e, na maior parte dos países, a eletricidade é a principal fonte de energia da indústria [Chyu e Chang, 2010; Park et al., 2009]. De acordo com a EPE [2020], a indústria brasileira responde por mais de 30% do consumo final de energia e quase 40% da eletricidade consumida no Brasil.

Levando em consideração que a parcela relativa ao consumo de energia elétrica se configura entre os três maiores custos de várias organizações na indústria brasileira, reduzir a conta de energia elétrica é uma ação importante para ajudar o setor industrial a diminuir seus crescentes custos de produção [Ecom, 2022]. À vista disso, resolver problemas de sequenciamento de produção são fundamentais para o sistema de sobrevivência do setor de manufatura, além de ser uma ferramenta que otimiza o uso dos recursos disponíveis e pode ser aplicado em diversos setores como, na produção de objetos de plásticos, de usinagem de peças, entre outros [Lacerda et al., 2016].

A questão central dos problemas de sequenciamento reside na busca pela otimização da alocação de recursos limitados ao longo de um horizonte de tempo. A relevância considerável desse desafio no contexto industrial origina-se do seu potencial impacto na eficiente distribuição de recursos [Pinedo, 2012]. Isso se reflete nos objetivos desta pesquisa, que incluem a redução do tempo total de execução *makespan* e a minimização do consumo total de energia.

Dentro do contexto da Pesquisa Operacional, problemas que envolvem múltiplos objetivos, são conhecidos como problemas de programação multiobjetivo. Em vez de fornecer apenas uma solução ideal básica para os diferentes objetivos, os problemas de otimização multiobjetivo oferecem ao tomador de decisões, ou também chamado *decision maker*, um conjunto de opções para identificar qual aspecto é mais importante em um determinado momento de consulta, de acordo com [de Souza Brandão e Cortez, 2008].

A tomada de decisão na otimização multiobjetivo requer a consideração de múltiplos critérios, os quais podem ser quantitativos e/ou qualitativos para compreender sua solução. Nessa tarefa desafiadora, é necessário empregar mecanismos que auxiliem na escolha, sendo essas ferramentas determinantes para a consideração de fatores relevantes que afetam a decisão [de Souza Brandão e Cortez, 2008].

Sendo assim, o presente estudo apresenta as seguintes contribuições: (i) apresentação de um problema de sequenciamento de tarefas em máquinas paralelas não-relacionadas multiobjetivo; (ii) construção de um conjunto de instâncias para esse problema (iii) aplicação do framework, pymoo, no problema em questão utilizando algoritmo genético NSGAII e R-NSGAII, Blank e Deb [2020]; (iv) elaborar um estudo experimental dos métodos propostos aplicados ao problema.

O restante do artigo está organizado da seguinte forma. Na Seção 2 apresenta-se uma Revisão Bibliográfica. Na Seção 3, encontra-se o Algoritmo Genético Multiobjetivo, NSGA-II e R-NSGA-II, Fronteira de Pareto, Ponto *Ideal* e Ponto *Nadir*. Na Seção 4, definição do problema, hiperparâmetros, Geração de Instâncias. Na Seção 5, apresenta-se os resultados computacionais obtidos e descreve-se o conjunto de instâncias. E por fim, na Seção 6 as conclusões e trabalhos futuros.

2. Revisão Bibliográfica

Para resolver um problema de máquinas paralelas não-relacionadas, Safarzadeh e Niaki [2023] apresentaram um problema de programação multiobjetivo, no qual o processamento de uma tarefa em uma máquina incorre em um determinado custo além do tempo de processamento. Para

este estudo os objetivos considerados são o *makespan* e o custo total, que são minimizados simultaneamente para obtenção de soluções ótimas de Pareto.

O estudo Afsar et al. [2022] abordou um problema de sequenciamento de máquinas paralelas não-relacionadas com duplo objetivo de minimizar o consumo de energia durante o tempo ocioso da máquina e minimizar o *makespan*. Propuseram um novo algoritmo memético combinando NSGA-II com três estratégias de intensificação e uma busca Tabu para otimização do *makespan*.

A pesquisa realizada por Wu e Che [2019] apresentou um problema de sequenciamento de máquinas paralelas não-relacionadas com um método de sequenciamento dinâmico de velocidade, e um objetivo para minimizar tanto o *makespan* quanto o consumo total de energia, aplicado a um novo algoritmo de evolução diferencial memético com heurística de ajuste de velocidade e troca de tarefas.

Os autores Cota et al. [2019] abordaram um problema de sequenciamento de máquinas paralelas não-relacionadas com tempos de setup, com a minimização do *makespan* e do consumo total de energia de cada máquina em diferentes modos de operação. Propuseram extensões multi-objetivos da metaheurística *Adaptive Large Neighborhood Search* (ALNS) com *Learning Automata* (LA).

O estudo de Tigane et al. [2019] trataram um problema de sequenciamento de máquinas paralelas não-relacionadas sujeitas a um efeito de deterioração, onde o tempo de processamento de cada tarefa é uma função de deterioração linear do tempo de início, o objetivo é determinar o melhor sequenciamento das tarefas, minimizando o *makespan* e o consumo total de energia, baseada em um algoritmo multiobjetivo de ordenação não-dominada (NSGA-II).

Em sua pesquisa Che et al. [2017] apresentaram um problema de sequenciamento de máquinas paralelas não-relacionadas multiobjetivo, sob tarifas de eletricidade por tempo de uso, com os objetivos de minimizar o custo de consumo de energia e o *makespan*, um modelo de programação linear inteira mista foi apresentado para o problema e propuseram uma heurística de dois estágios para problemas de tamanho grande.

3. Algoritmo Genético Multiobjetivo, NSGA-II e R-NSGA-II

Algoritmos Genéticos (AG) são fundamentados no princípio Darwiniano da evolução e genética das espécies. Estes são algoritmos probabilísticos que fornecem um mecanismo de busca paralelo e adaptativo baseado na ideia de reprodução e sobrevivência do mais apto [Golberg, 1989]. Uma ideia principal da evolução, como a recombinação e seleção, são aplicadas na elaboração de algoritmos robustos e que necessitam um mínimo de dados sobre o problema, segundo [Deb, 2001].

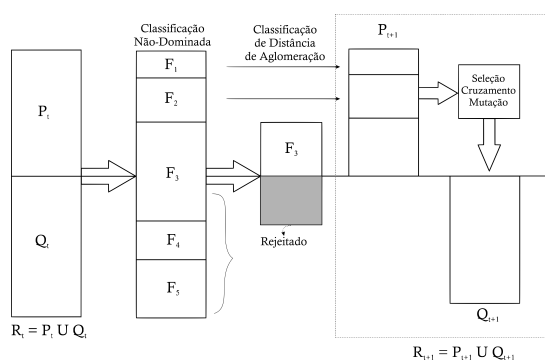
Para a resolução de problemas multiobjetivos, os processos variam entre métodos exatos e heurísticos, onde a solução é dada pelo conjunto ótimo da chamada Fronteira de Pareto, diante disso, um crescente número de algoritmos tem sido apresentado na literatura, tais como o *MultiObjective Genetic Algorithm* (MOGA), o *Niched-Pareto Genetic Algorithm* (NPGA), o *Non-dominated Sorting Genetic Algorithm* (NSGA-II), entre outros [Miloca et al., 2012].

O algoritmo NSGA-II, proposto por Deb [2001] se tornou um dos algoritmos mais utilizados para encontrar as soluções não-dominadas em problemas multiobjetivos, isso devido ao fato de exibir uma propriedade de elitismo e não precisar de nenhum parâmetro de compartilhamento.

De acordo com o autor Verma et al. [2021] o processo do NSGA-II utiliza o operador de distância de aglomeração para o mecanismo de preservação da diversidade, além disso é computacionalmente rápido. Seu processo é baseado em quatro princípios fundamentais: Seleção Não-Dominada, Operador de Elite, Distância de Aglomeração e Operador de Seleção. O funcionamento do algoritmo NSGA-II é mostrado na Figura 1, que apresenta uma população inicial P_t de tamanho

N . A partir dela, é gerada uma nova população descendente, Q_t , através de processos de seleção, cruzamento e mutação. As soluções não-dominadas (ND) são classificadas em frentes de Pareto e suas distribuições avaliadas utilizando método de distância de aglomeração (*crowding distance*), classificando-as em F_1, F_2, F_3 , etc. Na fase subsequente, essas soluções não-dominadas (ND) são selecionadas de forma elitista para compor a próxima população P_{t+1} , que por sua vez passa pelos processos de seleção, cruzamento e mutação resultando na população descendente Q_{t+1} .

Na mesma linha, o algoritmo R-NSGA-II adota uma estrutura geral semelhante ao NSGA-II, com uma modificação na seleção de sobrevivência. O objetivo original do algoritmo R-NSGA-II é fornecer pontos concentrados na região frontal de Pareto, levando em consideração as preferências do tomador de decisão (*Decision Maker*). Nesse contexto, o amplamente utilizado algoritmo R-NSGA-II enfrenta dificuldades em obter uma distribuição adequada de pontos que se aproximem de todas as partes da Fronteira de Pareto [Filatovas et al., 2017].



Fonte: Adaptado de [Verma et al., 2021].

Figura 1: Processo do NSGA-II


3.1. Fronteira de Pareto, Ponto *Ideal* e Ponto *Nadir*

Desenvolvido pelo economista italiano Vilfredo Pareto em 1896, a Fronteira de Pareto pode auxiliar na tomada de melhores decisões durante o processo de solução de problemas [Kádár, 2022]. As soluções ótimas de Pareto são apresentadas por meio de uma combinação no espaço objetivo do problema. Os limites dessa fronteira são alcançados minimizando cada uma das funções objetivo individualmente, sujeitas ao conjunto de restrições. O ponto *ideal* Z^* é determinado pelas melhores soluções de cada um dos objetivos otimizados individualmente, enquanto o ponto *nadir* Z^{nadir} é formado pelas piores soluções de cada um dos objetivos otimizados individualmente [Gonçalves, 2019], conforme ilustrado na Figura 2.

3.2. Métricas de Desempenho quando a Fronteira de Pareto é desconhecida

Diversos trabalhos utilizam a Fronteira Ótima de Pareto como referência para medir a qualidade da solução encontrada, nesses casos as soluções ótimas são conhecidas. No caso dos problemas onde não se conhece a solução ótima, pode-se utilizar dois parâmetros para avaliar o comportamento evolutivo dessas soluções, a convergência e a diversidade, já apresentado no estudo realizado por [Blank e Deb, 2020]. Durante a fase de convergência, as soluções não-dominadas (ND) são substituídas de forma contínua, levando em consideração a variação entre o ponto *ideal* antecessor e seu sucessor ($\Delta_{t-1,t} Z^*$), em relação ao valor definido como limiar, ϵ . Esse critério também é aplicado ao ponto *nadir* ($\Delta_{t-1,t} Z^{\text{nadir}}$). Dessa forma, as soluções ND da fronteira migram para pontos ND que melhoram o objetivo, conforme apresentado na Figura 3.

Após essa fase, as soluções são avaliadas quanto a sua diversidade onde serão selecionadas considerando o parâmetro de proximidade. Esse parâmetro permite, ou não, uma solução ND ser



Fonte: Adaptado de [El-Shorbagy e Mousa, 2021].

Figura 2: Fronteira de Pareto, Ponto *Ideal* e Ponto *Nadir*

incluída no conjunto de soluções que compõe a Fronteira de Pareto. Por fim, na Figura 4, observa-se o comportamento das soluções em cada geração, no caso, de 5 gerações representada pela linha azul e 10 gerações pela linha verde. Observa-se no quadrado vermelho o ponto de limite onde o valor da diferença máxima foram superiores ao ϵ , ocorrendo nesse caso uma melhoria nas soluções. O eixo vertical representa a métrica IGD (*Inverted Generational Distance*) foi adaptada, sendo $\phi_t^T = \text{IGD}(\bar{P}_{t-1}, \bar{P}_t)$, $\bar{P}_{t-1} = \frac{\bar{P}_{t-1} - Z_t^*}{Z_{\text{nadir}} - Z_t^*}$ [Blank e Deb, 2020].




Figura 3: Métricas do Ponto *Ideal* e Ponto *Nadir*.




Figura 4: Métrica de Desempenho.

Fonte: Adaptado de [Blank e Deb, 2020].

4. Definição do Problema, Hiperparâmetros e Geração de Instâncias

Para esse problema foram consideradas de 2 a 20 máquinas (M) e 10 a 400 tarefas (N), conforme a Tabela 1. O objetivo é minimizar simultaneamente o *makespan* e o consumo total de energia *TEC*, gerando a melhor Fronteira de Pareto possível para um problema multiobjetivo de N tarefas independentes em M máquinas paralelas não-relacionadas.

Fator N/M(M)	Número de Máquinas (M)	Número de Tarefas (N)
5(2)	2	10
10(2)	2	20
15(2)	2	30
20(2)	2	40
5(5)	5	25
10(5)	5	50
15(5)	5	75
20(5)	5	100
5(10)	10	50
10(10)	10	100
15(10)	10	150
20(10)	10	200
5(15)	15	75
10(15)	15	150
15(15)	15	225
20(15)	15	300
5(20)	20	100
10(20)	20	200
15(20)	20	300
20(20)	20	400

Tabela 1: Parâmetros de Entrada

Fator N/M(M)	Soluções ND NSGA-II	Soluções ND R-NSGA-II
5(2)	58	70
5(5)	9	10
5(10)	5	10
5(15)	7	4
5(20)	9	9
10(2)	14	13
10(5)	9	7
10(10)	8	10
10(15)	10	11
10(20)	6	14
15(2)	7	16
15(5)	6	9
15(10)	9	16
15(15)	10	9
15(20)	14	7
20(2)	13	8
20(5)	13	12
20(10)	5	8
20(15)	11	10
20(20)	16	15

Tabela 2: Soluções Não-Dominadas (ND)

Os tempos de processamento são gerados no intervalo $[1,99]$ com distribuição uniforme, o consumo de energia é gerado no intervalo $[40,200]$ com distribuição uniforme. Dessa forma, o consumo de energia é atribuído aleatoriamente para cada tarefa em cada máquina, possibilitando assim, consumos de energia menor para tarefas com maiores tempos de processamento (8,33% a 13,75% das instâncias possuem consumo de energia menor que o tempo das tarefas.), dados adaptados dos autores [COTA et al., 2019].

4.1. População Inicial

Para gerar a população inicial foi utilizada a estratégia aleatória de escolha individual de alocação de cada tarefa em uma respectiva máquina. Os parâmetros populacionais foram estabelecidos de 100, 200, 300 e 400 indivíduos proporcionalmente aos fatores N/M de 5, 10, 15 e 20, respectivamente. Os filhos possuem o mesmo número de indivíduos dos pais. O fator de cruzamento utilizado foi de 0,9, com método de dois pontos de cruzamento (*two point crossover*). Para a fase de mutação, foi utilizado o parâmetro $\text{ETA}=20$, em uma escala de 0 a 30. A seleção é realizada por torneio e a avaliação dos sobreviventes é feita pela classificação por níveis (*ranking*) e por densidade (*crowding*). Para o critério de parada foi estabelecido o número de 50 gerações. Critério de relaxamento: $\epsilon = 0,0025$ (0,25%) para NSGA-II e $\epsilon = 0,001$ (0,1%) para R-NSGA-II.

4.2. Modelo Matemático e Pseudocódigos

Problema de Alocação de Tarefas em Máquinas Paralelas Não-Relacionadas com objetivos de minimizar o *Makespan* e o Consumo Total de Energia

Parâmetros:

I : Conjunto de tarefas, $i = 1, 2, \dots, n$.

J : Conjunto de máquinas, $j = 1, 2, \dots, m$.

t_{ij} : Tempo necessário para a máquina j completar a tarefa i .

e_{ij} : Energia consumida pela máquina j ao realizar a tarefa i .

Variáveis de decisão:

$$x_{ij} = \begin{cases} 1 & \text{se a tarefa } i \text{ é atribuída à máquina } j, \\ 0 & \text{caso contrário.} \end{cases}$$

C_j : Tempo de conclusão de todas as tarefas alocadas a máquina j .

E_j : Energia consumida pela máquina j para realizar a tarefa i .

C_{max} : Makespan do conjunto de máquinas.

$$TEC = \sum_{j \in J} E[j].$$

Objetivos:

$$\text{Min } f1 = C_{max}$$

$$\text{Min } f2 = TEC$$

Restrições:

$$\sum_{j \in J} x_{ij} = 1 \quad \forall i \in I \quad (1)$$

$$C_j = \sum_{i \in I} t_{ij} x_{ij} \quad \forall j \in J \quad (2)$$

$$E_j = \sum_{i \in I} e_{ij} x_{ij} \quad \forall j \in J \quad (3)$$

$$C_{max} \geq C_j \quad \forall j \in J \quad (4)$$

$$x_{ij} = \{0, 1\} \quad \forall i \in I, \forall j \in J \quad (5)$$

Essa formulação matemática representa um problema de programação linear multiobjetivo. A melhor solução será um conjunto de soluções que compõem a Fronteira de Pareto, que minimizam simultaneamente os dois objetivos, *makespan* e consumo total de energia (*TEC*). A restrição (1) determina que cada tarefa *i* só pode ser atribuída a uma máquina. A restrição (2) indica que o tempo de conclusão da máquina *j* é a soma dos tempos das tarefas *i* atribuídas a ela. Na restrição (3) a energia consumida pela máquina *j* é a soma das energias das tarefas *i* atribuídas a ela. A restrição (4) indica que o *makespan* (C_{max}) é pelo menos o tempo de conclusão de cada máquina. E a restrição (5) é responsável pelo domínio das variáveis.

Algoritmo 1: PSEUDOCÓDIGO PARA NSGA-II E R-NSGA-II

```

1  Entrada Inicializa População
2  Gere N soluções aleatórias e insira em População
3  para i ← 1 até número máximo de gerações faça
4  início
5      Gere PopulaçãoProle de tamanho N
6      Selecione os Pais de População
7      Crie a Prole de Pais
8      Aplique mutação em Prole
9      Combine População e PopulaçãoProle em População Atual
10     para todos indivíduos em População Atual faça
11         | Atribua rank baseado no Pareto do Fast Non Dominated Sort
12     fim
13     Gere conjunto das soluções não-dominadas no Pareto
14     Calcule o Crowding Distance (NSGA-II)
15     Calcule o Reference point Based (RNSGA-II)
16     Selecione N melhores soluções começando no melhor front
17 fim
18 retorna os resultados ([makespan, consumo total de energia])

```

5. Resultados

Os experimentos computacionais foram escritos e executados em Linguagem Python utilizando Jupyter e em um computador com Sistema Operacional Windows 10 Pro, Processador AMD Ryzen 5 3400G Radeon, 3700Mhz, 4 núcleos e 8 processadores lógicos.

Após definido o problema, foi utilizado um *framework* de código aberto para otimização em Python, Pymoo, que oferece algoritmos de otimização para soluções mono e multiobjetivos, assim como outros recursos relacionados à otimização multiobjetivo, como visualização e tomada de decisão [Blank e Deb, 2020]. Na Figura 5 apresenta-se o gráfico obtido para o caso da instância 20x100, onde observa-se no Espaço de Objetivos a Fronteira de Pareto obtida após 50 gerações.



Figura 5: Espaço de Objetivos

A Figura 6, apresenta o comportamento individual de cada objetivo que compõe as soluções ND, sendo observado o comportamento conflitante.




Figura 6: Convergências do *Makespan* e Consumo Total.

Com o objetivo de avaliar a distribuição das soluções na Fronteira de Pareto e possibilitar uma comparação entre as soluções ND, aplica-se a Equação 6 que normaliza os valores, onde F representa cada solução ND no gráfico.

$$nF = \frac{(F - \text{Ponto Ideal})}{(\text{Ponto Nadir} - \text{Ponto Ideal})} \quad (6)$$

Para avaliar a distribuição das soluções na Fronteira de Pareto, gera-se um gráfico com os seguintes fatores de pesos, [0,999, 0,001], [0,75, 0,25], [0,5, 0,5], [0,25, 0,75] e [0,001, 0,999] que são responsáveis por direcionar para uma solução em que um dos objetivos são mais representativos que o outro, ou no caso de [0,5, 0,5] onde ambos são igualmente importantes. Na Figura 7, apresenta-se um exemplo para a instância 20x100, onde cada valor de semirreta foi medido e sua distribuição espacial avaliada para gerar a Tabela 5.

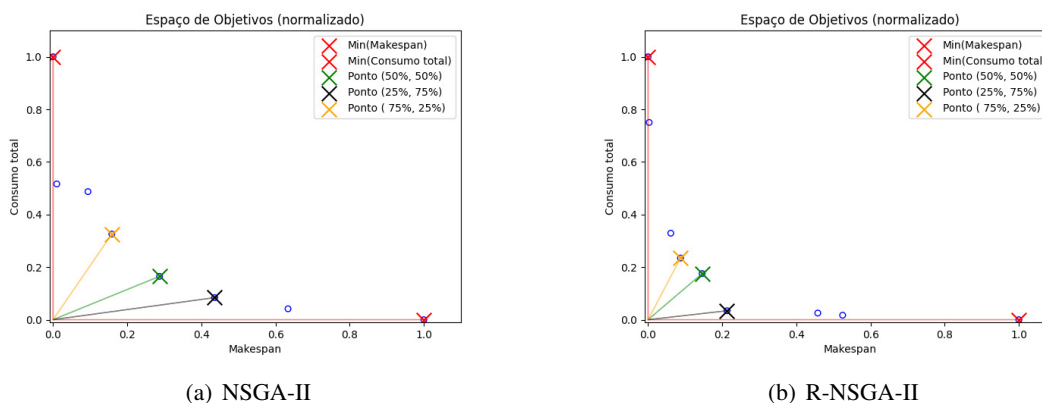


Figura 7: Espaço Normalizado NSGA-II e R-NSGA-II.

A Figura 8, apresenta um gráfico da evolução do algoritmo na busca de melhores soluções, aqui são demonstrados os pontos de convergência, que localizam as mudanças normalizadas nos Pontos *ideal* e Nadir $> \epsilon$, isso indica que o algoritmo está nas primeiras etapas de sua execução. Nessas etapas, ele está ativamente explorando o espaço de solução, fase denominada de convergência (CE), conforme referenciado na Figura 4.




Figura 8: Convergência a cada Geração do NSGA-II e R-NSGA-II.

A Tabela 2, observa-se que o algoritmo NSGA-II apresentou um número menor de soluções ND do que R-NSGA-II, em 45% das instâncias e, em um caso, houve empate.

Analisando a Tabela 3, observa-se que o algoritmo NSGA-II apresentou maior tempo de execução do que R-NSGA-II em 85% das instâncias. Adicionalmente nas colunas PC NSGA-II e PC R-NSGA-II onde estão apresentados os números de pontos de convergência obtidos a partir da Figura 8, observa-se que em 65% das instâncias o algoritmo NSGAII apresentou quantitativo superior. A Tabela 4, representa o ponto *ideal* de cada fronteira gerada, separada em colunas por algoritmo e objetivos. Assim, é possível, comparar qual a melhor solução projetada (ponto *ideal*) para cada conjunto de soluções ND ao final das gerações. Analisando individualmente cada objetivo (*makespan* e consumo total de energia), na Tabela 4 observa-se que o algoritmo R-NSGA-II foi capaz de obter os melhores resultados de *makespan* em 12 instâncias, ganhando do NSGA-II com 7 e instâncias e 1 empatada. Já em relação ao consumo total o algoritmo NSGA-II venceu em 12 instâncias contra 7 do R-NSGA-II e 1 instância empatada. Observa-se, ainda, que as instâncias 5(5), 5(10), 15(5), 20(5) e 20(15) obtiveram os menores valores em ambos os objetivos, com algoritmo NSGA-II. Já, as instâncias 5(20), 10(2), 10(5), 10(10) e 20(2) obtiveram com algoritmo R-NSGA-II. Para a instância 5(2) foi obtida a melhor solução para ambos os algoritmos.

Fator N/M(M)	TE NSGAII	TE R-NSGAII	PC NSGAII	PC R-NSGAII	Fator N/M(M)	MP NSGAII	MP R-NSGAII	CE NSGAII	CE R-NSGAII
5(2)	2,12	2,58	3	4	5(2)	199	199	10,36	1036
5(5)	3,04	3,26	7	5	5(5)	174	175	2213	2339
5(10)	4,7	4,86	5	6	5(10)	249	273	4849	4859
5(15)	6,68	6,82	7	8	5(15)	291	292	7342	7530
5(20)	8,9	8,96	6	3	5(20)	322	309	10582	10557
10(2)	4,5	4,69	9	6	10(2)	380	377	1894	1884
10(5)	6,88	7,32	7	6	10(5)	442	438	4875	4805
10(10)	12,06	12,32	7	7	10(10)	529	522	10591	10460
10(15)	18,37	18,51	9	6	10(15)	560	552	15635	15673
10(20)	25,47	25,64	5	9	10(20)	608	603	21475	21691
15(2)	7,25	7,66	8	7	15(2)	536	534	2676	2695
15(5)	12,19	12,65	5	8	15(5)	655	702	7994	8096
15(10)	22,49	23,01	11	6	15(10)	784	759	15946	16213
15(15)	35,71	35,17	7	3	15(15)	836	818	24343	24355
15(20)	50,37	50,17	7	4	15(20)	850	842	33156	33414
20(2)	10,53	11	8	6	20(2)	936	914	4529	4488
20(5)	18,57	19,6	7	6	20(5)	868	916	10587	10746
20(10)	36,21	36,5	7	6	20(10)	1003	1016	21847	21714
20(15)	58,52	58,14	6	5	20(15)	1080	1098	32929	33450
20(20)	84,83	83,31	5	9	20(20)	1105	1102	44355	44646

Tabela 3: Tempos de Execução (TE) e Pontos de Convergência (PC)

Tabela 4: Valores de *Makespan* (MP) e Consumo de Energia (CE)

Na Tabela 5, coluna "Avaliação Qualitativa" apresenta-se uma classificação, realizada a partir de uma análise visual com o objetivo de verificar a distribuição das semirretas no espaço normalizado. Assim, pode-se comparar as suas distribuições (que avalia diversidade) na Fronteira de Pareto.

Estabeleceu-se um padrão de classificação, > (símbolo de maior) significa que distribuição foi adequada, < (símbolo de menor) distribuição inadequada e quando ambos forem adequados, o melhor foi identificado com o sinal >> (símbolo duplo de maior).

Fator N/M(M)	Pontos NSGA-II			Pontos R-NSGA-II			Avaliação Qualitativa	
	Pt.50/50	Pt.25/75	Pt.75/25	Pt.50/50	Pt.25/75	Pt.75/25	(NSGA-II)	(R-NSGA-II)
5(2)	0,48	0,64	0,53	0,48	0,64	0,53	>	<
5(5)	0,41	0,68	0,41	0,39	0,63	0,39	<	<
5(10)	0,58	0,74	0,58	0,15	0,15	0,21	>	<
5(15)	0,41	0,63	0,7	0,18	0,18	0,18	>	<
5(20)	0,33	0,44	0,36	0,23	0,22	0,25	>	>
10(2)	0,63	0,61	0,74	0,6	0,82	0,72	>	<
10(5)	0,57	0,6	0,8	0,38	0,51	0,38	<	<<
10(10)	0,43	0,69	0,47	0,6	0,89	0,73	>	>
10(15)	0,42	0,68	0,54	0,47	0,47	0,41	>	>>
10(20)	0,44	0,72	0,44	0,37	0,41	0,53	<	>
15(2)	0,47	0,66	0,77	0,38	0,37	0,34	>	>
15(5)	0,54	1	0,54	0,31	0,48	0,31	<	<
15(10)	0,33	0,33	0,51	0,33	0,43	0,48	<	>
15(15)	0,3	0,3	0,51	0,34	0,34	0,4	<	<
15(20)	0,36	0,34	0,48	0,55	0,76	0,62	>	>
20(2)	0,36	0,39	0,5	0,33	0,49	0,44	>>	>
20(5)	0,66	0,74	0,66	0,42	0,45	0,63	>>	>
20(10)	0,53	0,81	0,53	0,65	0,94	0,7	<	>
20(15)	0,41	0,53	0,39	0,29	0,29	0,51	>	<
20(20)	0,59	0,53	0,83	0,39	0,32	0,54	>	>

Tabela 5: Classificação e Distribuição dos Semirretas no Espaço Normalizado.

Ainda, na Tabela 5, uma análise quantitativa foi realizada a partir das medidas de comprimentos das semirretas (Figura 7), devendo apresentar valores menores para a posição 50/50 do que para as demais, devido à natureza das Fronteiras de Pareto geradas. Essas medidas são compatíveis com o que visualmente se observa. Em termos de melhores distribuições obteve-se 13 instâncias utilizando NSGA-II e somente 12 instâncias com R-NSGA-II. Observa-se, ainda, que 9 instâncias apresentaram resultados adequados com ambos os algoritmos e 4 instâncias apresentaram resultados inadequados com ambos.

6. Conclusões e Trabalhos Futuros

A abordagem proposta proporcionou um estudo inicial de alocação de tarefas em máquinas paralelas não-relacionadas com bi-objetivos. Obteve-se em todas as instâncias a Fronteira de Pareto. Em relação ao tempo computacional o NSGA-II realizou o processamento no menor tempo em 85% das instâncias. Verifica-se que para esse problema o algoritmo NSGA-II foi capaz de encontrar mais soluções com valores menores

de Consumo de Energia Total, de 60%, já o R-NSGA-II gerou valores menores de *makespan*, de 60%. Essa informação pode ser levada em consideração na tomada de decisão, considerando o objetivo a ser atingido. Observa-se também, a compatibilidade entre os valores medidos das semirretas com o verificado visualmente nos gráficos, quanto a distribuição da Fronteira de Pareto. Constatou-se com isso que o algoritmo NSGA-II apresenta distribuições adequadas em 65% das instâncias e o R-NSGA-II, em 60%. Essa distribuição mais uniforme e mais próxima do ponto *ideal*, permite maior possibilidade de escolha, melhorando o suporte ao Gerente do Processo na sua tomada de decisão.

Para os trabalhos futuros pode-se analisar qual é o melhor compromisso entre *makespan* e consumo de energia, através de uma avaliação heurística da Fronteira de Pareto. Pode-se também utilizar uma solução gulosa na geração da população inicial e verificar se há uma redução nos tempos de execução. Pode-se especificar a relação de consumo energético com a sua tarifação, gerar penalidades quando tarefas de alto consumo energético são realizadas em horários de maior tarifação. Assim, esse problema poderá ser expandido para muitas situações reais, com relativa facilidade de uso do *framework*, com tempos de execução aceitáveis e boas soluções.

Referências

- Afsar, S., Palacios, J. J., Puente, J., Vela, C. R., e González-Rodríguez, I. (2022). Multi-objective enhanced memetic algorithm for green job shop scheduling with uncertain times. *Swarm and Evolutionary Computation*, 68:101016.
- Blank, J. e Deb, K. (2020). A running performance metric and termination criterion for evaluating evolutionary multi-and many-objective optimization algorithms. In *2020 IEEE Congress on Evolutionary Computation (CEC)*, p. 1–8. IEEE.
- Che, A., Zhang, S., e Wu, X. (2017). Energy-conscious unrelated parallel machine scheduling under time-of-use electricity tariffs. *Journal of Cleaner Production*, 156:688–697.
- Chyu, C.-C. e Chang, W.-S. (2010). A pareto evolutionary algorithm approach to bi-objective unrelated parallel machine scheduling problems. *The International Journal of Advanced Manufacturing Technology*, 49:697–708.
- Cota, L. P., Guimarães, F. G., Ribeiro, R. G., Meneghini, I. R., de Oliveira, F. B., Souza, M. J., e Siarry, P. (2019). An adaptive multi-objective algorithm based on decomposition and large neighborhood search for a green machine scheduling problem. *Swarm and Evolutionary Computation*, 51:100601.
- COTA, L. P., GUIMARES, F. G., DE OLIVEIRA, F. B., SOUZA, M. J. F., e MIRANDA, G. M. (2019). Algoritmo multiobjetivo de busca adaptativa em vizinhança de larga escala para o sequenciamento de tarefas em máquinas considerando consumo de energia elétrica. In *Congresso Brasileiro de Automática-CBA*, volume 1.
- de Souza Brandão, R. e Cortez, J. M. R. (2008). A comprehensive review on nsga-ii for multi-objective combinatorial optimization problems. *IEEE Access*.
- Deb, K. (2001). Multi-objective optimization using evolutionary algorithms john wiley & sons. *Inc., New York, NY*.
- Ecom (2022). Indústria e energia: qual é a relação entre os setores? [urlhttps://ecomenergia.com.br/blog/industria-e-energia-impulsionam-a-economia/](https://ecomenergia.com.br/blog/industria-e-energia-impulsionam-a-economia/).
- El-Shorbagy, M. A. e Mousa, A. A. A. (2021). Constrained multiobjective equilibrium optimizer algorithm for solving combined economic emission dispatch problem. *Complex.*, 2021:6672131:1–6672131:14.
- EPE (2020). Propostas de medidas no setor industrial brasileiro. [urlhttps://www.epe.gov.br/pt/publicacoes-dados-abertos/publicacoes/caderno-sobre-acoes-de-eficiencia-energetica-em-industrias-brasileiras](https://www.epe.gov.br/pt/publicacoes-dados-abertos/publicacoes/caderno-sobre-acoes-de-eficiencia-energetica-em-industrias-brasileiras).

- Filatovas, E., Lančinskas, A., Kurasova, O., e Žilinskas, J. (2017). A preference-based multi-objective evolutionary algorithm r-nsga-ii with stochastic local search. *Central European Journal of Operations Research*, 25:859–878.
- Giret, A., Trentesaux, D., e Prabhu, V. (2015). Sustainability in manufacturing operations scheduling: A state of the art review. *Journal of Manufacturing Systems*, 37:126–140.
- Golberg, D. E. (1989). Genetic algorithms in search, optimization, and machine learning. *Addison wesley*, 1989(102):36.
- Gonçalves, E. (2019). Uma metodologia determinística à resolução de problemas multiobjetivo de despacho e de fluxo de potência.
- Kádár, P. (2022). Multi objective energy mix optimalization. In *2022 IEEE 26th International Conference on Intelligent Engineering Systems (INES)*, p. 000187–000192. IEEE.
- Lacerda, H., Feitosa, A., Filho, A., Dos Santos, W., e Cordeiro, F. (2016). Redução de energia em casas inteligentes utilizando uma abordagem multiobjetivo baseada nos perfis de uso de equipamentos.
- Miloca, S. A., Faria, T. M. B., e Volpi, N. M. P. (2012). Aplicação de algoritmo genético multiobjetivo em otimização de portfólios.
- Park, C.-W., Kwon, K.-S., Kim, W.-B., Min, B.-K., Park, S.-J., Sung, I.-H., Yoon, Y. S., Lee, K.-S., Lee, J.-H., e Seok, J. (2009). Energy consumption reduction technology in manufacturing—a selective review of policies, standards, and research. *International journal of precision engineering and manufacturing*, 10:151–173.
- Pinedo, M. L. (2012). *Scheduling*, volume 29. Springer.
- Safarzadeh, H. e Niaki, S. (2023). Unrelated parallel machine scheduling with machine processing cost. *International Journal of Industrial Engineering Computations*, 14(1):33–48.
- Tigane, M., Dahane, M., e Boudhar, M. (2019). Multiobjective approach for deteriorating jobs scheduling for a sustainable manufacturing system. *The International Journal of Advanced Manufacturing Technology*, 101:1939–1957.
- Verma, S., Pant, M., e Snasel, V. (2021). A comprehensive review on nsga-ii for multi-objective combinatorial optimization problems. *IEEE Access*, 9:57757–57791.
- Wu, X. e Che, A. (2019). A memetic differential evolution algorithm for energy-efficient parallel machine scheduling. *Omega*, 82:155–165.